

المپیاد هوش مصنوعی | آزمون تئوری جامع | تابستان ۱۴۰۵

به نام خدا

• مدت آزمون: ۱۸۰ دقیقه

• مجموع نمره: ۱۰۰

• استفاده از ماشین حساب غیربرنامه ریزی شده مجاز است.

• پاسخ هر سؤال باید به صورت کامل و با استدلال ریاضی نوشته شود؛ پاسخ بدون استدلال نمره کامل دریافت نمی کند.

• در تمام سؤالات، $\|\cdot\|$ بدون اندیس یعنی نرم اقلیدسی، و $1[\cdot]$ تابع نشانگر است که در صورت برقراری شرط مقدار 1 و در غیر این صورت مقدار 0 می گیرد.

سؤال ۱ – طبقه بندی بیزی، تخمین MAP و تصمیم کمینه ریسک (۲۰ نمره)

یک آزمایشگاه پزشکی قصد دارد بر اساس d ویژگی باینری $x \in \{0, 1\}^d$ (نتایج d آزمایش تشخیصی) تشخیص دهد که آیا بیمار به یک بیماری نادر مبتلاست ($y = 1$) یا سالم است ($y = 0$). مدل مولد (generative) زیر را در نظر بگیرید:

• احتمال پیشین بیماری: $P(y = 1) = \pi$ با $0 < \pi < 1$;

• به ازای هر ویژگی $j \in \{1, \dots, d\}$:

$$P(x_j = 1 | y = 1) = p_j, \quad P(x_j = 1 | y = 0) = q_j,$$

و ویژگی ها به شرط y مستقل از هم هستند (فرض Naive Bayes). فرض کنید $p_j > q_j$ برای همه j است؛ یعنی هر آزمایش، نتیجه مثبت را با بیماری سازگارتر می کند.

(الف) – طبقه بندی بهینه (۴ نمره). نشان دهید طبقه بند بیز-بهینه (کمینه ساز احتمال خطا) برابر است با قاعده «weighted voting»: پیش بینی $\hat{y} = 1$ اگر و تنها اگر

$$\sum_{j=1}^d w_j x_j \geq \theta, \quad w_j = \ln \frac{p_j(1 - q_j)}{q_j(1 - p_j)}, \quad \theta = -\ln \frac{\pi}{1 - \pi} - \sum_{j=1}^d \ln \frac{1 - p_j}{1 - q_j}.$$

(ب) – تخمین ماکسیمم a posteriori با پیشین Beta (۵ نمره). فرض کنید p_1 مجهول است و بقیه پارامترها معلوم اند. برای نمونه های بیمار مجموعه آموزش $\{x^{(i)} : y^{(i)} = 1\}$ با اندازه n_+ درست نمایی را به صورت تابعی از p_1 بنویسید و با قراردادن پیشین $p_1 \sim \text{Beta}(\alpha, \beta)$ نشان دهید تخمین ماکسیمم a posteriori برابر است با

$$\hat{p}_1^{\text{MAP}} = \frac{s_+ + \alpha - 1}{n_+ + \alpha + \beta - 2},$$

که در آن $s_+ = \sum_{x^{(i)} \in S_+} x_1^{(i)}$ تعداد نتایج مثبتِ ویژگیِ اول در بیماران است. توضیح دهید در چه حالتی این تخمین با تخمین بیشینه درست‌نمایی (MLE) یکی می‌شود و چرا افزودن پیشین می‌تواند از نرخ خطای طبقه‌بندی نهایی بکاهد.

(ج) - **تصمیم کمینه‌ریسک با هزینه نامتقارن (۵ نمره).** بیماری آن‌قدر نادر و خطرناک است که هزینه «از دست دادن بیمار مبتلا» (تشخیص دیر هنگام) برابر C_{10} و هزینه «هشدار کاذب» برابر C_{01} است، با $C_{10} > C_{01} > 0$. نشان دهید تصمیم کمینه‌ریسک همان قاعدهٔ بخش (الف) است اما با آستانهٔ جدید

$$\theta_{\text{risk}} = -\ln\left(\frac{\pi}{1-\pi} \cdot \frac{C_{10}}{C_{01}}\right) - \sum_{j=1}^d \ln \frac{1-p_j}{1-q_j}.$$

سپس برای حالت خاص $d=1$, $p_1=0.9$, $q_1=0.2$, $\pi=0.05$ و $C_{10}=9C_{01}$ ، ریسک کلی (میانگین هزینه) تصمیم کمینه‌ریسک را به صورت عدد دقیق (کسر، بر حسب C_{01}) محاسبه کنید.

(د) - **مقایسهٔ مولد و تمایزی (۶ نمره).** به مدل مولد بالا مدل تمایزی رگرسیون لجستیک $\hat{P}(y=1|x) = \sigma(w_0 + \sum_j w_j x_j)$ را با همان مقادیر w_j بخش (الف) و $w_0 = -\theta$ مقایسه کنید.

۱. نشان دهید این مدل لجستیک با مدل مولدِ بخش (الف) دقیقاً هم‌ارز است؛ یعنی $P(y=1|x)$ حاصل از قاعدهٔ بیز برابر همان سیگموئید است. (کافی است ثابت کنید w_j ها همان لگاریتم نسبت بخت‌ها هستند).

۲. حال فرض کنید فرض استقلال شرطی ویژگی‌ها (Naive Bayes) برقرار نباشد و در حقیقت ویژگی‌های فرد بیمار همبسته باشند. استدلال کنید کدامیک از دو مدل (مولدِ Naive Bayes یا discriminative logistic regression) در برابر نقض این فرض **مقاوم‌تر** است و کدامیک خطای مدل‌سازی سیستماتیک دارد؛ برای مدل مولد، مثالی عددی در $d=2$ بسازید که در آن احتمال پسین واقعی از خروجی مدل Naive Bayes فاصلهٔ معنادار (حداقل 0.15) داشته باشد.

سؤال ۲ - gradient boosting با هزینهٔ Huber و درخت‌های تصمیم (۲۰ نمره)

در این سؤال الگوریتم gradient boosting را روی تابع هزینه‌ای غیرمتعارف تحلیل می‌کنیم. مجموعهٔ آموزش $D = \{(x_i, y_i)\}_{i=1}^n$ با $x_i \in \mathbb{R}$ و $y_i \in \mathbb{R}$ داریم و مدل ترکیبی مرحله‌به‌مرحله (stagewise) به صورت

$$F_m(x) = F_{m-1}(x) + \eta h_m(x), \quad m = 1, 2, \dots, M$$

ساخته می‌شود؛ $0 < \eta \leq 1$ نرخ یادگیری و h_m یک «weak learner» (decision stump، یعنی تابع پله‌ای با یک پله) است. تابع هزینهٔ نمونه‌محور $L(y, \hat{y})$ را چنین تعریف می‌کنیم ($\delta > 0$ ثابت است):

$$L(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| \leq \delta \\ \delta |y - \hat{y}| - \frac{1}{2}\delta^2, & |y - \hat{y}| > \delta \end{cases}$$

(سطر اول: ناحیهٔ درون؛ سطر دوم: ناحیهٔ بیرونی - هزینهٔ Huber)

(الف) - **گرادیان pseudo-residual (۵ نمره).** در مرحلهٔ m ، مقدار

$$r_i = - \left. \frac{\partial L(y_i, z)}{\partial z} \right|_{z=F_{m-1}(x_i)}$$

را به صورت تکه‌ای بر حسب باقیمانده $e_i = y_i - F_{m-1}(x_i)$ حساب کنید. سپس نشان دهید با انتخاب $\delta \rightarrow \infty$ این روش به gradient boosting با هزینه مربعی و با $\delta \rightarrow 0^+$ (پس از ضرب هزینه در $1/\delta$) به gradient boosting با هزینه قدرمطلق میل می‌کند؛ یعنی دو حد انتهایی این خانواده دقیقاً همان دو رژیم کلاسیک‌اند.

(ب) - **برازش stump روی گرادیان (۵ نمره).** نشان دهید stump بهینه برای برازش مقادیر r_i روی نقاط مرتب‌شده $x_{(1)} \leq \dots \leq x_{(n)}$ (با مقادیر همراه $(r_{(1)}, \dots, r_{(n)})$ همیشه یکی از $n-1$ شکاف میان نقاط متوالی است، و شاخص بهینه k^* کمینه‌ساز

$$\sum_{i \leq k} (r_{(i)} - \bar{r}_L(k))^2 + \sum_{i > k} (r_{(i)} - \bar{r}_R(k))^2, \quad \bar{r}_L(k) = \frac{1}{k} \sum_{i \leq k} r_{(i)}, \quad \bar{r}_R(k) = \frac{1}{n-k} \sum_{i > k} r_{(i)}$$

است و stump بهینه برابر $h(x) = \bar{r}_L(k^*) \mathbf{1}[x \leq t_{k^*}] + \bar{r}_R(k^*) \mathbf{1}[x > t_{k^*}]$ می‌شود. (راهنمایی: در فضای توابع پله‌ای با یک پله، جست‌وجوی کامل روی شکاف‌ها و بهینه‌سازی مستقیم مقدار پله‌ها یعنی میانگین‌گیری در هر طرف؛ درستی گام «میانگین‌گیری» را با استدلال «صفر شدن گرادیان در هر ناحیه» اثبات کنید.)

(ج) - **محاسبه دستی (۵ نمره).** مجموعه داده کوچک زیر (مرتب‌شده بر حسب x) را در نظر بگیرید:

5	4	3	2	1	i
4	3	2	1	0	x_i
4.0	3.5	3.0	0.5	0.0	y_i

مرحله اول gradient boosting با هزینه Huber بالا، $\delta = 1$ ، $\eta = 1$ و $F_0 \equiv 0$ را دقیقاً و عدد به عدد اجرا کنید: مقادیرهای r_i ، stump بهینه h_1 (شکاف و دو سطح)، و مقدارهای $F_1(x_i)$ را گزارش کنید. سپس r_i های مرحله دوم را حساب کنید و توضیح دهید کدام شکاف برای stump دوم بهینه است.

(د) - **نرخ یادگیری و بهینه‌سازی در فضای توابع (۵ نمره).** فرض کنید η به جای 1 مقدار کوچکی مثل 0.1 باشد و M به اندازه کافی بزرگ انتخاب شود. با استدلالی درباره «بهینه‌سازی در فضای توابع» (function-space optimization) و تجزیه بایاس-واریانس، توضیح دهید چرا انتخاب $\eta < 1$ معمولاً تعمیم (عملکرد تست) بهتری نسبت به $\eta = 1$ می‌دهد، حتی وقتی هر دو در حد $M \rightarrow \infty$ به همان حد آموزشی می‌رسند. (استدلال کیفی دقیق، با ارجاع به نقش هموارسازی مسیر بهینه‌سازی، کافی است.)

سؤال ۳ - SVM: هندسه margin، مسائل dual و kernel (۲۰ نمره)

داده آموزش دودویی $\{(x_i, y_i)\}_{i=1}^n$ با $x_i \in \mathbb{R}^d$ و $y_i \in \{-1, +1\}$ داریم. مسئله SVM با soft-margin (پارامتر $C > 0$) به صورت primal زیر است:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.t. } y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

(الف) – **dual و شرایط KKT (۵ نمره).** با ساخت Lagrangian و صفر قراردادن گرادین نسبت به w , b و ξ , نشان دهید مسئله dual برابر است با

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{s.t. } 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^n y_i \alpha_i = 0,$$

و حل‌کننده primal از رابطه $w = \sum_i \alpha_i y_i x_i$ بازسازی می‌شود. سپس با نوشتن شرایط تکمیلی slackness, مشخص کنید در چهار حالت $\alpha_i = 0$, $0 < \alpha_i < C$, $\alpha_i = C$ با $\xi_i = 0$ و $\alpha_i = C$ با $\xi_i > 0$, نقطه x_i نسبت به ابرصفحه جداکننده و حاشیه‌ها در کجا قرار دارد (دقیقاً روی margin, درون margin, یا خطاکار).

(ب) – **حل دستی روی داده کوچک (۵ نمره).** داده یک‌بعدی زیر را در نظر بگیرید: سه نقطه منفی در $x \in \{0, 1, 2\}$ و سه نقطه مثبت در $x \in \{3, 4, 5\}$ (همه نقاط روی خط واقعی). برای C به اندازه کافی بزرگ (رژیم جداسازی‌پذیر، $\xi_i = 0$):

1. با استدلال هندسی، جداکننده بهینه و support vectors را بیابید.

2. با حل مستقیم مسئله primal در این حالت، مقدار دقیق w , b , geometric margin γ و مقدار بهینه objective برایمال را محاسبه کنید.

3. مقدارهای α_i را به‌طوری که شرایط KKT را ارضا کنند تعیین کنید و نشان دهید رابطه $\sum_i \alpha_i = \|w\|^2$ برقرار است (این رابطه از تساوی مقادیر بهینه primal و dual نتیجه می‌شود).

(ج) – **kernel و نگاشت ویژگی (۵ نمره).** تابع $k(x, z) = (x^\top z)^2$ روی $\mathbb{R}^2$ را در نظر بگیرید.

1. نگاشت ویژگی صریح $\phi: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ را بیابید به‌طوری که $k(x, z) = \phi(x)^\top \phi(z)$.

2. مجموعه داده چهارنقطه‌ای زیر (الگوی XOR) را در نظر بگیرید:

$$x_1 = (1, 1), y_1 = +1, \quad x_2 = (-1, -1), y_2 = +1, \quad x_3 = (1, -1), y_3 = -1, \quad x_4 = (-1, 1), y_4 = -1.$$

نشان دهید این نقاط در فضای ویژگی نگاشت ϕ با یک ابرصفحه جدا می‌شوند و SVM hard-margin روی آن‌ها را در فضای ویژگی دقیقاً حل کنید: بردار w , بایاس b , geometric margin γ و مقدارهای α_i . آیا این چهار نقطه در فضای اصلی $\mathbb{R}^2$ با یک خط جدا می‌شوند؟ چرا؟ 3. نشان دهید هر چهار نقطه support vector هستند و رابطه $\sum_i \alpha_i = \|w\|^2$ نیز در فضای ویژگی برقرار است.

(د) – **ناوردایی تحت تبدیل‌های همسانی (۵ نمره).** فرض کنید همه نمونه‌ها در یک تبدیل همسانی (تشکیل‌شده از

چرخش/بازتاب و مقیاس یکنواخت) $x \mapsto Ax$ با $A = \rho Q$ شرکت کنند؛ $Q \in \mathbb{R}^{d \times d}$ متعامد است و $\rho > 0$.

1. نشان دهید اگر (w^*, b^*) حل SVM hard-margin روی داده اصلی باشد، حل روی داده تبدیل‌یافته برابر

$$(\tilde{w}^*, \tilde{b}^*) = \left(\frac{1}{\rho} Q w^*, b^* \right)$$

تصویر مرز قدیم زیر همین تبدیل است.

2. آیا support vectors همان نقاط باقی می‌مانند؟ geometric margin چگونه تغییر می‌کند؟ نسبت حاشیه به

مقیاس داده چگونه است؟ اثبات کنید.

3. نشان دهید (یا با یک مثال متقاعد کنید) که برای تبدیل خطی عمومی غیرهمسانی این ناوردایی برقرار نیست و توضیح دهید چرا؛ سپس توضیح دهید چرا k-NN با فاصله اقلیدسی حتی نسبت به مقیاس‌گذاری غیریکنواخت ویژگی‌ها حساس است و نقش استانداردسازی/فاصله مالهالانویس (مثل آنچه در مدل GMM دیدید) در برطرف کردن این حساسیت چیست.

سؤال ۴ – PCA (Principal Component Analysis) و linear autoencoder (۲۰ نمره)

داده‌های $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$ با میانگین صفر و ماتریس کوواریانس متقارن $\Sigma = \frac{1}{n} \sum_i x_i x_i^\top$ با مقادیر ویژه $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0$ و بردارهای ویژه متناظر $u_1, \dots, u_d$ (متعامد یک‌ه) را در نظر بگیرید.

(الف) – خواص پایه (۴ نمره). ثابت کنید:

$$1. \text{Tr}(\Sigma) = \sum_{j=1}^d \lambda_j = \frac{1}{n} \sum_{i=1}^n \|x_i\|^2.$$

2. برای هر ماتریس $P \in \mathbb{R}^{d \times k}$ با $P^\top P = I_k$ ، رابطه $\text{Tr}(P^\top \Sigma P) = \frac{1}{n} \sum_{i=1}^n \|P^\top x_i\|^2$ برقرار است.

(ب) – PCA به صورت بهترین رتبه k (۷ نمره). نشان دهید رابطه زیر برقرار است:

$$\max_{P \in \mathbb{R}^{d \times k}, P^\top P = I_k} \text{Tr}(P^\top \Sigma P) = \lambda_1 + \dots + \lambda_k,$$

و بیشینه در $P^* = [u_1, \dots, u_k]$ (بردارهای ویژه $\lambda_1, \dots, \lambda_k$) به دست می‌آید. (راهنمایی: می‌توانید از اصل کمکی-بیشینه یا از بسط $P = [u_1, \dots, u_k]Q + R$ با شرط $R^\top [u_1, \dots, u_k] = 0$ استفاده کنید؛ در حالت تکرار مقادیر ویژه، مجموعه بهینه ممکن است یکتا نباشد.)

(ج) – linear autoencoder (۶ نمره). یک linear autoencoder یک‌لایه‌ی پنهان با کد کردن و رمزگشایی خطی

$$\hat{x} = UVx, \quad V \in \mathbb{R}^{k \times d}, U \in \mathbb{R}^{d \times k}$$

و تابع هزینه $\mathcal{J}(U, V) = \frac{1}{n} \sum_{i=1}^n \|x_i - UVx_i\|^2$ را در نظر بگیرید.

1. نشان دهید مقدار بهینه سراسری این مسئله برابر $\sum_{j>k} \lambda_j$ است؛ یعنی هیچ جفت (U, V) هزینه‌ای کمتر از خطای

بازسازی PCA با k مؤلفه نمی‌دهد. سپس نشان دهید یک بهینه سراسری با $V = [u_1, \dots, u_k]^\top$ و $U =$

$[u_1, \dots, u_k]$ وجود دارد که در آن $VV^\top = I_k$ و $U = V^\top$ ؛ به بیان دیگر، بهینه خطی بدون قید تعامد، عملاً همان

PCA است. (راهنمایی: برای هر (U, V) ثابت کنید UV می‌تواند با یک تصویرکردن متعامد رتبه k حذف نشود، بلکه

هزینه آن دست‌کم به اندازه بهترین تصویر متعامد رتبه- k است؛ می‌توانید ابتدا با SVD از UV یا با تعویض متغیر

$W = UV$ و استدلال «بهترین W رتبه k در معیار $\| \Sigma^{1/2}(I - W) \|_F^2$ » پیش بروید.)

2. اگر به جای MSE از هزینه $\mathcal{J}_\Sigma(U, V) = \frac{1}{n} \sum_i (x_i - UVx_i)^\top \Sigma (x_i - UVx_i)$ استفاده شود، نشان دهید بهینه

سراسری روی همان زیرفضای دهانه $u_1, \dots, u_k$ (بردارهای ویژه Σ) باقی می‌ماند و مقدار بهینه برابر $\sum_{j>k} \lambda_j^2$ است.

(د) – پیوند با داده‌های واقعی (۳ نمره). توضیح دهید در داده‌های تصویر چهره (مثل مجموعه AT&T با تصاویر $112 \times$

92)، چرا مقدار ویژه اول λ_1 معمولاً به‌طور قابل توجهی از بقیه بزرگ‌تر است و این موضوع چه رابطه‌ای با «چهره متوسط»

و ساختار همبستگی شدت پیکسل‌ها دارد؛ و چرا انتخاب $k = 50$ مؤلفه برای بازسازی با خطای نسبتاً کم معمولاً کافی است، در حالی که همین تصاویر به‌طور میانگین تنها چند درصد از کل واریانس را در پیکسل‌های جداگانه و بی‌همبسته نشان می‌دادند. (پاسخ کیفی و دقیق کافی است).

سؤال ۵ - شبکه‌های عصبی: backpropagation، پایداری گرادیان و expressivity (نمره ۲۰)

شبکه عصبی با L لایه پنهان و عرض ثابت m را در نظر بگیرید:

$$h^{(0)} = x, \quad h^{(\ell)} = \sigma(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)}), \quad \ell = 1, \dots, L, \quad \hat{y} = w^{(L+1)\top}h^{(L)} + b^{(L+1)},$$

که در آن σ تابع فعال‌سازی است و برای هر لایه $\|W^{(\ell)}\|_2 \leq M_\ell$ (نرم طیفی) و برای همه z ، $|\sigma(z)| \leq 1$ و $|\sigma'(z)| \leq 1$ (به‌عنوان مثال $\tanh$). تابع هزینه مربعی اسکالر $L_{\text{sq}} = \frac{1}{2}(\hat{y} - y)^2$ در نظر بگیرید.

(الف) - **قاعده backpropagation عمومی (۵ نمره)**. با تعریف $\delta^{(L+1)} = \frac{\partial L_{\text{sq}}}{\partial a^{(L+1)}}$ با $a^{(L+1)} = w^{(L+1)\top}h^{(L)} + b^{(L+1)}$ و به‌طور بازگشتی $\delta^{(\ell)} = ((W^{(\ell+1)})^\top \delta^{(\ell+1)}) \odot \sigma'(a^{(\ell)})$ ، نشان دهید

$$\frac{\partial L_{\text{sq}}}{\partial W^{(\ell)}} = \delta^{(\ell)} (h^{(\ell-1)})^\top, \quad \frac{\partial L_{\text{sq}}}{\partial h^{(\ell-1)}} = (W^{(\ell)})^\top \delta^{(\ell)}.$$

و نشان دهید نرم گرادیان نسبت به وزن‌های لایه اول با حاصل‌ضرب جاکوبین‌ها به‌صورت $\|\delta^{(1)}\| \leq \|\delta^{(L+1)}\| \prod_{\ell=2}^{L+1} \|W^{(\ell)}\|_2$ کنترل می‌شود.

(ب) - **محاسبه دستی روی شبکه کوچک (۵ نمره)**. شبکه $L = 2$ با $m = 1$ نورون در هر لایه پنهان (شبکه زنجیره‌ای) و فعال‌سازی سیگموئید $\sigma(z) = (1 + e^{-z})^{-1}$ را در نظر بگیرید، با وزن‌های اسکالر

$$w^{(1)} = 1, \quad b^{(1)} = 0, \quad w^{(2)} = -2, \quad b^{(2)} = 0, \quad w^{(3)} = 3, \quad b^{(3)} = 0,$$

و ورودی $x = 1$ ، هدف $y = 1$. مقادیرهای $\hat{y}$ ، $h^{(1)}$ ، $h^{(2)}$ ، مقادیرهای $\delta^{(1)}$ ، $\delta^{(2)}$ ، $\delta^{(3)}$ و گرادیان‌های $\frac{\partial L}{\partial w^{(3)}}$ ، $\frac{\partial L}{\partial w^{(2)}}$ ، $\frac{\partial L}{\partial w^{(1)}}$ را دقیقاً به‌صورت عبارت‌های بسته بر حسب e بنویسید.

(ج) - **exploding gradient و vanishing gradient گرادیان (۴ نمره)**. با استفاده از کران بخش (الف)، نشان دهید اگر همه وزن‌ها با مقیاس مشابه $\beta \approx \|W^{(\ell)}\|_2$ مقداردهی شوند:

۱. اگر $\beta < 1$ ، گرادیان‌های لایه‌های ابتدایی به‌صورت نمایی $\mathcal{O}(\beta^L)$ کوچک می‌شوند (vanishing gradient)؛

۲. اگر $\beta > 1$ ، حد بالای گرادیان‌ها به‌صورت نمایی رشد می‌کند و پایداری آموزش را تهدید می‌کند (exploding gradient).

(gradient). سپس با ارجاع به تحلیل استاندارد مقداردهی Xavier/Glorot برای $\tanh$ (یعنی $\text{Var}[w_{ij}] = \frac{2}{m_\ell + m_{\ell+1}}$) یا معادل نرم طیفی مورد انتظار (≈ 1) ، توضیح دهید چرا این انتخاب، مقیاس گرادیان را در سراسر عمق شبکه متعادل نگه می‌دارد.

(د) – expressivity و محدودیت معماری (۶ نمره).

1. نشان دهید شبکه‌های با فعال‌سازی tanh از قدرت universal approximation برخوردارند؛ به صورت دقیق‌تر: برای هر $\varepsilon > 0$ و تابع پیوسته f روی مکعب $[0, 1]^d$ ، شبکه‌ای یک‌لایه با عرض **متناهی** مناسب m و فعال‌سازی tanh وجود دارد که $\sup_{x \in [0, 1]^d} |f(x) - \hat{f}(x)| \leq \varepsilon$ (می‌توانید از تقریب‌پذیری توابع پیوسته توسط ترکیب‌های خطی از tanh یا از قضیه Stone–Weierstrass استفاده کنید).
2. شبکه‌های با یک نورون در هر لایه پنهان ($m = 1$) و فعال‌سازی سیگموئید را در نظر بگیرید. نشان دهید تابع $x \mapsto x^2$ روی $[-1, 1]$ را **هیچ** شبکه‌ای از این نوع نمی‌تواند دقیقاً محاسبه کند. (راهنمایی: ترکیب توابع اکیداً صعودی با توابع صعودی، خود تابعی صعودی است؛ اما x^2 روی $[-1, 1]$ صعودی نیست).
3. یک حد بالای صریح برای تعداد نواحی خطی (مناطق شبه‌خطی) تابع خروجی یک شبکه ReLU با L لایه و عرض حداکثر m روی ورودی $\mathbb{R}$ ارائه دهید، و با مقایسه با شمارش توابع قطعه‌ای-خطی با Lm گره روی $\mathbb{R}$ توضیح دهید چرا عمق می‌تواند به صورت نمایی بازده بیشتری نسبت به عرض به همراه بیاورد.

سؤال ۶ (تشریحی-تحلیلی، اختیاری برای نمره اضافه) – ارتباط مفاهیم (۵ نمره اضافه، صرفاً در صورت نمره کامل در سایر سؤالات)

در یک پاراگراف تحلیلی و دقیق، ارتباط مفهومی سه مورد زیر را توضیح دهید: «بهینه‌سازی در فضای توابع» در gradient boosting (سؤال ۲)، «بهترین تقریب رتبه k » در PCA (سؤال ۴)، و «بهینه‌سازی بر حسب ترکیب خطی توابع پایه» در شبکه‌های عصبی با عرض زیاد (سؤال ۵). به طور خاص توضیح دهید چرا هر سه را می‌توان نمونه‌ای از «برازش مرحله‌ای/تصویرکردن داده به زیرفضای کم‌بعد Span توابع یا جهت‌های بهینه» دانست.

پایان آزمون تئوری – موفق باشید