


۱. یک درخت رگرسیون استاندارد مانند شکل ۱ با اندازه ثابت را در نظر بگیرید. این مدل ۵ پارامتر عددی $(s_1, s_2, v_1, v_2, v_3)$ و دو انتخاب گسسته برای ویژگی تقسیم دارد که با اعداد صحیح j و k نشان داده می‌شوند. مجموعه داده آموزشی

$\mathcal{D}_{\text{train}} = \{(x^{(i)}, y^{(i)})\}_{i=1}^n$ داده شده است که بعد هر $x^{(i)}$ برابر d است. تابع زیان مربعی کل این مدل را به صورت زیر تعریف می‌کنیم که $T(x^{(i)})$ خروجی مدل درخت است.

$$L = \sum_{i=1}^n \left(y^{(i)} - T(x^{(i)}) \right)^2$$



شکل ۱: درخت اولیه

(الف) عبارت $T(x^{(i)})$ را به دست آورید.

(ب) توضیح دهید چرا نمی‌توان با Gradient descent بر روی تابع زیان فوق، همه پارامترهای این مدل را بهینه کرد.

حال قصد داریم درختی «هموارتر» بسازیم؛ برای این منظور آزمون‌های گره‌ها را با دسته‌بندی لجستیکی شبکه عصبی جایگزین می‌کنیم و پیش‌بینی‌های شاخه‌ها را با هم ترکیب کرده تا بتوانیم درخت را به صورت یک مدل پارامتری در نظر بگیریم و پارامترها را با گرادینت بهینه کنیم. به طور مشخص، در هر گره داخلی، آزمون با $\text{NN}(x; \theta)$ جایگزین می‌شود؛ شبکه عصبی‌ای که کل بردار ورودی $x \in \mathbb{R}^d$ را می‌گیرد و با استفاده از یک واحد سیگموئید در خروجی، عددی در بازه $[0, 1]$ تولید می‌کند. می‌توان هر گره T_i از درخت را این گونه به عنوان یک تابع خروجی در نظر گرفت:

• اگر T_i یک برگ باشد، آنگاه خروجی روی ورودی x برابر یک ثابت v_i است، یعنی $T_i(x) = v_i$.

• اگر T_i یک گره داخلی با دو فرزند T_{no} (متعلق به شاخه «نه») و T_{yes} (متعلق به شاخه «بله») باشد، آنگاه خروجی روی ورودی x برابر است با


$$T_i(x) = (1 - \text{NN}(x; \theta^{(i)})) T_{\text{no}}(x) + \text{NN}(x; \theta^{(i)}) T_{\text{yes}}(x)$$

به بیان دیگر، این خروجی ترکیبی وزن دار از نتایج دو فرزند است که در آن شبکه عصبی والد با پارامترهای $\theta^{(i)}$ ضرایب این ترکیب را تنظیم می‌کند.

در حالت خاصی که NN تنها یک واحد با تابع فعال‌سازی سیگموید باشد، داریم

$$\text{NN}(x; W^{(i)}, W_0^{(i)}) = \sigma((W^{(i)})^\top x + W_0^{(i)})$$


که در آن $W^{(i)}$ برداری به طول d ، $W_0^{(i)}$ یک اسکالر، و σ تابع سیگموید است.



شکل ۲: درخت با گره‌هایی از جنس شبکه عصبی

(ج) در این مدل خاص شکل ۲، مقدار $\frac{\partial T_1(x)}{\partial W^{(1)}}$ را به دست آورید.

مجموعه داده نشان داده شده در شکل ۳ را در نظر بگیرید که در آن $d = 2$ است. هر عدد صحیح روی نمودار (یکی از 5، -2 یا 8) متناظر با یک نقطه داده است که ویژگی‌های ورودی x همان مختصات آن نقطه روی نمودار بوده و مقدار خروجی y برابر عدد چاپ شده است.



شکل ۳: مجموعه داده آموزش

(د) همه‌ی پارامترهای مدل شکل ۲ را برای این داده‌های آموزش شکل ۳ به دست آورید.

به دلیل ساختار تکراری درخت‌های رگرسیون (مشابه ایده اشتراک وزن در CNN)، اگر در همه گره‌های داخلی از یک بردار وزن W و یک بایاس W_0 یکسان استفاده کنیم. حال فرض کنید که برگ‌ها $T(x) = v_\ell$ ثابت هستند و در تمام گره‌های داخلی پارامترها $((W^{(i)}, W_0^{(i)}))$ مشترک‌اند و برابر مقادیر ثابت (W, W_0) باشند. این مدل را «درخت عصبی یکنواخت» می‌نامیم.

(ه) مجموعه توابعی که قابل بیان توسط خروجی «درخت عصبی یکنواخت» را مشخص کنید.

(و) اگر در هر گره‌ی داخلی «درخت عصبی یکنواخت» به جای تابع سیگموید از آزمون/بله/خیر $H(W^\top x + W_0)$ که $H(z) = \{z > 0\}$ استفاده کنیم، مجموعه توابعی که قابل یادگیری توسط این مدل هستند را مشخص کنید.


یادآوری یک تعریف را باهم ببینیم. تابع مشخصه^۱ برای یک شرط منطقی به صورت زیر تعریف می‌شود:

$$I[\text{شرط}] = \begin{cases} 1 & \text{اگر شرط برقرار باشد} \\ 0 & \text{اگر شرط برقرار نباشد} \end{cases}$$

به عنوان مثال:

$$I[x > 0] = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases}$$

این تابع مثل یک کلید روشن/خاموش عمل می‌کند و در بسیاری از مسائل به ما کمک می‌کند که شرطها را داخل یک فرمول جمع‌بندی کنیم.



شکل ۴: نمایی از تابع مشخصه

۲. در بسیاری از کاربردهای واقعی، داده‌هایی که مدل‌های یادگیری ماشین دریافت می‌کنند کامل و بی‌نقص نیستند. این نواقص می‌توانند ناشی از خطاهای سنسورها، نویز در تصاویر، یا هرگونه اختلال کوچک دیگر در فرآیند جمع‌آوری داده باشند. یک مدل مقاوم^۲ مدلی است که در برابر چنین تغییرات کوچکی پایدار مانده و دچار افت عملکرد شدید نشود. اما همیشه این تغییرات تصادفی نیستند؛ گاهی به‌طور هدفمند و هوشمندانه طراحی می‌شوند. تصور کنید یک مهاجم^۳ به مدل شما دسترسی دارد و هدفش فریب دادن آن است. او تلاش می‌کند با کوچک‌ترین تغییر در ورودی، بیشترین خطای ممکن را در خروجی ایجاد کند. این امر می‌تواند در عمل بسیار خطرناک باشد. برای مثال، مهاجم می‌تواند در یک مدل پردازش تصویر غیرمقاوم تغییراتی اعمال کند که برای چشم انسان نامحسوس است، اما مدل را وادار به خروجی دلخواه خود کند. چنین مدلی اگر برای تشخیص چهره یا کنترل دسترسی استفاده شود، پیامدهای جدی خواهد داشت. بنابراین هدف ما طراحی مدلی است که در «بدترین حالت» نیز عملکرد مناسبی داشته باشد.

این مساله را می‌توان به صورت یک بازی دو نفره دید:

- مدل‌ساز (ما): بردار وزن $w \in \mathbb{R}^d$ را انتخاب می‌کنیم.
- مهاجم: پس از مشاهده‌ی w ، برای هر نمونه‌ی (x_i, y_i) نویز δ_i اضافه می‌کند تا خطای مربعی را بیشینه کند، به شرط آنکه $\|\delta_i\|_2 \leq \epsilon$ باشد.

Indicator Function^۱
Robust^۲
Adversary^۳

با بازی تعریف شده، در نهایت مساله به یک مساله‌ی کمینه-بیشینه^۴ خواهد بود که فرم ریاضی به شکل زیر است:

$$\min_w \sum_{i=1}^N \left(\max_{\|\delta_i\|_2 \leq \epsilon} (y_i - (x_i + \delta_i)^T w)^2 \right)$$

جدول ۱: نمادهای به کار رفته در سوال نبرد مدل و مهاجم

نماد	توضیح
N	تعداد نمونه‌های داده
d	تعداد ویژگی‌ها
$x_i \in \mathbb{R}^d$	بردار ویژگی‌های ورودی نمونه‌ی i ام
$y_i \in \mathbb{R}$	مقدار هدف نمونه‌ی i ام
$w \in \mathbb{R}^d$	بردار وزن‌های مدل
$\hat{y}_i = x_i^T w$	پیش‌بینی مدل
$\delta_i \in \mathbb{R}^d$	نویز خصمانه اعمال‌شده روی نمونه‌ی i ام
ϵ	بودجه‌ی مهاجم؛ حداکثر اندازه‌ی مجاز بردار نویز
X	ماتریس داده‌ها با ابعاد $N \times d$ که هر سطر آن x_i^T است
λ	پارامتر تنظیم در رگرسیون

(الف) فرض کنید مدل و وزن‌های w داده شده‌اند. برای یک نمونه‌ی (x, y) ، نویز δ^* بیابید که مساله‌ی زیر را حل کند:

$$\max_{\|\delta\|_2 \leq \epsilon} (y - (x + \delta)^T w)^2$$

راهنمایی: عبارت $(y - x^T w - \delta^T w)^2$ را بازنویسی کنید.

به خاطر دارید که در رگرسیون Ridge استاندارد (که در ادامه با «رگرسیون استاندارد» از آن یاد می‌کنیم) تابع هزینه‌ی به صورت $\|y - Xw\|_2^2 + \lambda \|w\|_2^2$ است. حال با توجه به استراتژی بهینه‌ی مهاجم δ_i^* ، تابع هدف به شکل فرمول زیر بازنویسی می‌شود که زین پس آن را تابع هدف مدل «رگرسیون مقاوم» می‌نامیم:

$$\mathcal{L}_{\text{robust}}(w) = \sum_{i=1}^N (|y_i - x_i^T w| + \epsilon \|w\|_2)^2$$

(ب) رابطه‌ی تابع هدف مدل «رگرسیون مقاوم» $\mathcal{L}_{\text{robust}}(w)$ نوشته شده در بالا را اثبات کنید.

(ج) در رابطه‌ی تابع هدف «رگرسیون مقاوم»، گرادیان $\mathcal{L}_{\text{robust}}(w)$ را نسبت به w محاسبه نمایید.

(د) توضیح دهید چرا بهینه‌سازی تابع هدف «رگرسیون مقاوم»، سخت‌تر از تابع هدف «رگرسیون استاندارد» است.

(ه) نقش جمله‌ی $\epsilon \|w\|_2$ در تابع هدف «رگرسیون مقاوم» چیست و چگونه برهم‌کنش آن با جمله‌ی $|y_i - x_i^T w|$ مقاومت مدل را افزایش می‌دهد؟ با استفاده از روابط ریاضی به دست آمده در بخش‌های قبل پاسخ دهید.


۳. در این سوال قصد داریم قدرت تخمین یک شبکه‌ی عصبی را بررسی کنیم. یک شبکه‌ی عصبی با دولایه‌ی مخفی را در نظر بگیرید. وزن‌های و بایاس‌های این شبکه را برای لایه‌ی اول و دوم به ترتیب (W_1, b_1) و (W_2, b_2) می‌نامیم. فرض کنید که وزن‌ها و بایاس‌ها در ابتدای کار از یک توزیع گاوسی مناسب به صورت تصادفی مقداردهی شده‌اند. همچنین در این سوال W_2 را ثابت فرض کنید اما b_1 و W_1 و b_2 را می‌توان در فرایند آموزش تغییر داد.

(الف) تابع غیرخطی فعال‌سازی را f در نظر بگیرید. همچنین فرض کنید شبکه در هر لایه تنها از یک نورون تشکیل شده است. رابطه‌ی ورودی و خروجی شبکه (یعنی نگاشت $h: x \mapsto h(x)$) را بنویسید.

(ب) تابع فعال‌ساز را ReLU یا ReLU- فرض کنید. در این صورت نشان دهید که هر تابع دلخواه به صورت زیر را می‌توان با این شبکه‌ها ساخت.

$$h(x) = \begin{cases} 0 & x < p \\ \alpha(x - p) & p \leq x \leq q \\ \alpha(q - p) & q < x \end{cases} \quad (۱)$$

که در رابطه‌ی بالا $p \in \mathbb{R}$ و $q \in \mathbb{R}$ دو عدد دلخواه به صورت $p < q$ و $\alpha \in \mathbb{R}$ شیب دلخواه است. به عنوان مثال در شکل ۵، $p = ۱$ ، $q = ۳$ ، $\alpha = ۲$ است.



شکل ۵: یک نمونه از تابع $h(x)$

(ج) نشان دهید با داشتن توابعی به شکل $h(x)$ می‌توان هر تابع دلخواه روی یک دامنه‌ی فشرده ۵ از اعداد حقیقی را با دقت دلخواه تخمین زد. (یک مجموعه $K \subseteq \mathbb{R}$ را فشرده می‌نامیم اگر (۱) بسته باشد یعنی همه‌ی نقاط حدی خودش را داشته باشد. (۲) کران‌دار باشد یعنی در بازه‌ای محدود بگنجد. برای مثال $[a, b]$ با شرط $a < b$ یک دامنه‌ی فشرده است. $\{0\} \cup [1, 2]$ فشرده است چون بسته و کران‌دار است. (a, b) فشرده نیست چون بسته نیست. $[a, +\infty)$ فشرده نیست چون کران‌دار نیست.)

(د) حال پاسخ خود را تعمیم دهید یعنی نشان دهید هر تابع دلخواه در $n \in \mathbb{N}$ بعد را می‌توان با داشتن تعداد کافی نورون با دقت دلخواه تخمین زد.

۴. قصد داریم با استفاده از رگرسیون لجستیک داده‌های آموزشی $\{(x_i, y_i)\}$, $i = 1, \dots, n$, $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ را به طوری که x_i یک بردار ویژگی d بعدی و y_i یک برچسب دودویی دسته‌بندی است مدل کنیم. به پرسش‌های زیر در رابطه با این الگوریتم پاسخ دهید:

(الف) لجستیک رگرشن در پیش‌بینی، چه چیزی را به صورت احتمال مدل می‌کند؟

(ب) نشان دهید بیشینه کردن تابع $\log \text{likelihood}$ بر روی داده‌های آموزشی معادل کمینه کردن تابع هزینه زیر است. (بردار وزن‌های مدل $w \in \mathbb{R}^d$ است که قصد تخمین آن را داریم.)

$$J(w) = - \sum_{i=1}^n \left[y_i \log(p(y_i | x_i; w)) + (1 - y_i) \log(1 - p(y_i | x_i; w)) \right]$$

(ج) با استفاده از بخش قبل، مشتق تابع $\log \text{likelihood}$ را نسبت به w بدست آورید. همچنین توجه کنید که این مسأله بهینه‌سازی جواب بسته (closed form) ندارد. یک روش برای بدست آوردن جواب این الگوریتم پیشنهاد دهید.

(د) نشان دهید مرز تصمیم‌گیری (منحنی‌ای که در فضای ویژگی داده‌های دوکلاسه را از هم تفکیک می‌کند) در این الگوریتم یک تابع خطی است.

۵. واحد پژوهش یک بیمارستان در حال توسعه‌ی مدل‌های مبتنی بر هوش مصنوعی برای تشخیص یک بیماری ژنتیکی نادر از روی داده‌های زیستی بیماران است. به دلیل نادر بودن این بیماری، تنها ۱٪ از مراجعین دارای بیماری هستند (کلاس مثبت با برچسب ۱) و ۹۹٪ مراجعین سالم هستند (کلاس منفی با برچسب ۰). بنابراین با یک دسته‌بندی نامتوازن روبرو هستیم. یک دسته‌بند برای جداسازی داده‌های دو دسته آموزش داده شده است ولی برای داده‌های تست علیرغم دقت بالا عملکرد مناسبی ندارد. در این سوال به دنبال ریشه‌یابی و ارائه‌ی راه‌حل برای این مشکل هستیم. مشکل رایج در این موارد، غلبه‌ی کلاس اکثریت (کلاس با تعداد نمونه‌های بیشتر) در طول فرآیند بهینه‌سازی است که می‌تواند به نقطه‌ی بهینه‌ی نامطلوبی منجر شود؛ به طوری که مدل از کلاس اقلیت صرف‌نظر کند و حتی نمونه‌های آزمون یا تست متعلق به کلاس اقلیت هم به کلاس اکثریت منتسب شوند. در این مسأله، از تابع زیان رگرسیون لجستیک با دوکلاس^۶ یا همان کراس آنترپی^۷ (CE) برای آموزش مدل استفاده شده است:

$$L(p(x), y) = -[y \log(p(x)) + (1 - y) \log(1 - p(x))]$$

که $p(x)$ احتمال تعلق نمونه x به کلاس مثبت را نشان می‌دهد. فرض کنید از بین N نمونه‌ی آموزش، تعداد N_0 نمونه به کلاس ۰ و N_1 نمونه به کلاس ۱ تعلق دارند.

(الف) اگر هر داده d ویژگی داشته باشد و از دسته‌بند خطی با تابع زیان بالا استفاده شود یک پاسخ برای وزن‌های مدل ارائه کنید که احتمال خطای آن روی توزیع داده‌ها ۱٪ باشد.

(ب) یکی از راهکارهای جلوگیری از مشکل بالا، استفاده از وزن متفاوت برای دو جمله در تابع زیان نوشته شده در بالا است. تابع زیان وزن‌دار مناسب را پیشنهاد کنید و رابطه‌ی مربوط به وزن هر جمله را مشخص کنید. علت انتخاب وزن‌های خود را توضیح دهید.

(ج) راه‌حل دیگر برای دسته‌بندی نامتوازن، بیش‌نمونه‌برداری^۸ نمونه‌های کلاس اقلیت است. بیش‌نمونه‌برداری با نرخ C به این معناست که هر نمونه از کلاس اقلیت C بار در مجموعه‌ی آموزش تکرار شود. حال فرض کنید در تابع زیان بند قبل، برای جمله‌ی اول ضریب C نظر گرفته شود و بهینه‌سازی با استفاده از گرادینان کاهشی دسته‌کامل^۹ انجام شود. با روابط ریاضی

^۶ Binary Logistic Regression

^۷ Cross Entropy

^۸ Oversampling

^۹ Full Batch Gradient Descent

نشان دهید استفاده از این تابع وزن دار معادل بیش‌نمونه‌برداری کلاس ۱ با نرخ C (تکرار هر کدام از نمونه‌های دسته‌ی ۱ به اندازه‌ی C بار در مجموعه‌ی داده‌ی آموزش) و استفاده از تابع زیان ساده نوشته شده $L(p(x), y)$ است.

(د) نشان دهید چگونه بیش‌نمونه‌برداری در بهینه‌سازی با گرادیان کاهشی تصادفی^{۱۰} می‌تواند نسبت به روش دسته‌کامل^{۱۱} به فرار از بهینه‌ی نامطلوب این مساله کمک بیشتری کند.

(ه) برای بهبود عملکرد دسته‌بندی در حالت داده‌های نامتوازن، تابع زیان زیر پیشنهاد شده است ($\gamma > 1$):

$$\tilde{L}(p(x), y) = -[y(1 - p(x))^\gamma \log(p(x)) + (1 - y)p(x)^\gamma \log(1 - p(x))]$$

با استدلال مشخص کنید این تغییر تابع هزینه، دسته‌بندی در شرایط نامتوازن را بهبود می‌بخشد یا بدتر می‌کند؟