

۱. مجموعه‌ای از داده‌های دوبعدی به صورت زیر داده شده است:

$$S = \{(1, 2), (2, 3), (3, 5), (4, 4), (5, 6)\}$$

(الف) با استفاده از الگوریتم PCA، مؤلفه‌های اصلی اول و دوم (PC1 و PC2) را محاسبه و مشخص کنید.

(ب) داده‌ها را به فضای جدید (فضای مؤلفه‌های اصلی) منتقل کنید.

(ج) اگر فقط از مؤلفه اول (PC1) برای بازسازی داده‌ها استفاده شود، چند درصد از واریانس داده‌ها حفظ می‌شود؟

(د) فرض کنید داده‌ها به جای مؤلفه‌های اصلی، روی راستای دلخواهی به شکل $a\vec{v}_1 + b\vec{v}_2$ تصویر شوند، که $\vec{v}_1$ و $\vec{v}_2$ بردارهای ویژه‌ی ماتریس کوواریانس داده‌ها هستند. فرمولی پارامتری برای واریانس داده‌ها در این راستا به دست آورید و توضیح دهید در چه حالتی این واریانس بیشینه می‌شود.

۲. در این سؤال، از داده‌های موجود در **The Database of Faces (AT&T)** استفاده می‌کنیم که این مجموعه داده شامل ۴۰۰ تصویر چهره افراد مختلف است، که هر تصویر 112×92 پیکسل است. تصاویر به صورت سیاه و سفید هستند، بنابراین هر پیکسل با یک عدد حقیقی بین ۰ (مشکی) و ۱ (سفید) نمایش داده می‌شود. ماتریس Σ به صورت یک ماتریس 10304×10304 تعریف می‌شود:

$$\Sigma = \frac{1}{n-1} \sum_{i=1}^n x_i x_i^T$$

که در آن، بردارهای x_i نقاط موجود در مجموعه داده (به صورت بردارهای ستونی) هستند و n تعداد کل تصاویر است. حال، ۵۰ مؤلفه‌ی اصلی برتر (PCA Dimensions) را محاسبه کنید؛ این مؤلفه‌ها، ۵۰ بُعدی هستند که بهترین بازسازی از داده‌ها را انجام می‌دهند.

(الف) مقادیر ویژه $\lambda_1, \lambda_2, \lambda_{10}, \lambda_{30}, \lambda_{50}$ را محاسبه کنید. همچنین، مجموع مقادیر ویژه $\sum_{i=1}^d \lambda_i$ را بنویسید. (راهنما: از جواب سؤال قبلی استفاده کنید.)

(ب) از سوال قبل می‌دانیم که خطای بازسازی نسبی هنگام استفاده از k مؤلفه‌ی اصلی برابر است با:

$$1 - \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i}$$

این خطای نسبی را برای $k=1$ تا $k=50$ رسم کنید. محور افقی (X) برابر k و محور عمودی (Y) مقدار خطای نسبی باشد. نمودار را به صورت واضح و با برجستگی مناسب ارائه دهید.

(ج) با استفاده از بخش‌های قبل توضیح دهید که اولین مقدار ویژه (eigenvalue) چه چیزی را نمایش می‌دهد، و چرا فکر می‌کنید λ_1 به طور قابل توجهی از بقیه بزرگ‌تر است.

۳. تحلیل مؤلفه‌های اصلی (PCA) یک الگوریتم کاهش ابعاد است که ماتریس داده را به صورت مجموعه‌ای از مؤلفه‌های اصلی نمایش می‌دهد که نسبت به یکدیگر متعامد (orthogonal) هستند. هر یک از این مؤلفه‌های اصلی، یک منبع از تغییرات موجود در ماتریس داده اولیه را ثبت می‌کند، به طوری که می‌توان ابعاد داده را کاهش داد و در عین حال، تا جای ممکن اطلاعات آن را حفظ کرد.

مؤلفه‌های اصلی به صورت بردارهای ویژه (eigenvectors) ماتریس کوواریانس داده تعریف می‌شوند؛ بنابراین، ما PCA را با استفاده از تجزیه ویژه (eigendecomposition) پیاده‌سازی خواهیم کرد.

اثر ماتریس M ، که با $\text{Tr}(M)$ نشان داده می‌شود، برابر است با مجموع درایه‌های قطری ماتریس M . اکنون چند قضیه را اثبات می‌کنیم که در مسئله‌ی بعدی مفید خواهند بود. تعریف می‌کنیم:

$$\Sigma := \frac{1}{n} X^T X$$

که در آن X یک ماتریس داده $n \times d$ است. فرض کنید x_i سطر i -ام ماتریس X است (یعنی x_i یک بردار d -بعدی است). همچنین، فرض کنید $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ مقادیر ویژه‌ی ماتریس Σ باشند.

(الف) دو خاصیت زیر را اثبات کنید:

$$\text{Tr}(\Sigma) = \sum_{i=1}^d \lambda_i \quad \bullet$$

$$\text{Tr}(\Sigma) = \frac{1}{n-1} \sum_{i=1}^n \|x_i\|_2^2 \quad \bullet$$

نکته ۱: ماتریس‌های متقارن به صورت متعامد قطری‌پذیر هستند، یعنی یک ماتریس متقارن A را می‌توان به شکل $A = UDU^T$ نوشت که در آن D یک ماتریس قطری حاوی مقادیر ویژه‌ی A در قطر اصلی و U یک ماتریس متعامد است که ستون‌هایش بردارهای ویژه‌ی A هستند.

نکته ۲: برای دو ماتریس A و B داریم:

$$\text{Tr}(AB^T) = \text{Tr}(B^T A)$$

(ب) فرض کنید P یک ماتریس افکنش $d \times k$ است که $P^T P = I_k$. افکنش از $\mathbb{R}^{n \times d}$ به $\mathbb{R}^{n \times k}$ به شکل زیر تعریف می‌شود:

$$X \mapsto XP$$

• نشان دهید:

$$\arg \max_{P \in \mathbb{R}^{d \times k}, P^T P = I} \text{Tr} \left(\frac{1}{n} P^T X^T X P \right) = P^*$$

که در آن هر ستون از P^* بردار ویژه‌ی u_i متناظر با λ_i است، برای $i = 1, \dots, k$. توجه کنید که u_i و λ_i همان بردارها و مقادیر ویژه‌ی Σ هستند.

• اثبات کنید که:

$$\text{Tr} \left(\frac{1}{n} P^{*T} X^T X P^* \right) = \sum_{i=1}^k \lambda_i$$

با استفاده از نتایج بدست آمده، داریم:

$$1 - \frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_d} = 1 - \frac{\sum_{i=1}^n \|P^{*T} x_i\|_2^2}{\sum_{i=1}^n \|x_i\|_2^2}$$

این معیار به عنوان خطای بازسازی PCA با استفاده از k جهت از d جهت اصلی شناخته می‌شود.

۴. فرض کنید $\mathbf{x}_1, \dots, \mathbf{x}_m$ بردارهایی در فضای $\mathbb{R}^d$ باشند و $\mathbf{x}$ یک بردار تصادفی با توزیع یکسان روی $\mathbf{x}_1, \dots, \mathbf{x}_m$ باشد. همچنین فرض کنید $\mathbb{E}[\mathbf{x}] = \mathbf{0}$.

مسئله یافتن بردار واحد $\mathbf{w} \in \mathbb{R}^d$ را در نظر بگیرید به طوری که متغیر تصادفی $\langle \mathbf{w}, \mathbf{x} \rangle$ دارای واریانس ماکزیمم باشد. یعنی می‌خواهیم مسئله زیر را حل کنیم:

$$\operatorname{argmax}_{\mathbf{w}: \|\mathbf{w}\|=1} \operatorname{Var}[\langle \mathbf{w}, \mathbf{x} \rangle] = \operatorname{argmax}_{\mathbf{w}: \|\mathbf{w}\|=1} \frac{1}{m} \sum_{i=1}^m \langle \mathbf{w}, \mathbf{x}_i \rangle^2$$

نشان دهید که جواب این مسئله این است که $\mathbf{w}$ را برابر اولین مؤلفه اصلی بردارهای $\mathbf{x}_1, \dots, \mathbf{x}_m$ قرار دهیم.

۵. در مسائل دسته‌بندی، تابع خطای استاندارد که معمولاً به عنوان هدف کمینه‌سازی در نظر گرفته می‌شود، تابع خطای $1/0$ یا خطای دودویی نام دارد و به صورت زیر تعریف می‌گردد:

$$\ell(f(x), y) = \mathbb{I}\{f(x) \neq y\},$$

که در آن $f(x), y \in \{0, 1\}$ هستند و مسئله در چارچوب طبقه‌بندی دودویی (binary classification) قرار می‌گیرد. در این سؤال، قصد داریم اثر استفاده از یک تابع خطای نامتقارن را بررسی کنیم که به صورت زیر معرفی می‌شود:

$$\ell_{\alpha, \beta}(f(x), y) = \alpha \cdot \mathbb{I}\{f(x) = 1, y = 0\} + \beta \cdot \mathbb{I}\{f(x) = 0, y = 1\}.$$

در این تابع خطا، دو نوع خطای ممکن دارای وزن‌های متفاوتی هستند که با ضرایب $\alpha, \beta > 0$ مشخص می‌شوند.

(الف) فرض کنید کلاس $y = 0$ بسیار نادر است، به گونه‌ای که احتمال وقوع آن یعنی $P(y = 0)$ بسیار کوچک باشد. در چنین شرایطی، یک دسته‌بند ساده همچون $f(x) = 1$ که بدون توجه به ورودی، همواره مقدار ۱ را پیش‌بینی می‌کند، ممکن است ریسک نسبتاً پائینی داشته باشد؛ زیرا تنها در موارد نادری که واقعاً $y = 0$ رخ دهد، دچار خطا می‌شود. تابع خطای معمولی $1/0$ به همه‌ی خطاها وزن یکسانی اختصاص می‌دهد. در این پرسش نشان دهید که چگونه با انتخاب مقادیر مناسب برای α و β در تابع خطای نامتقارن $\ell_{\alpha, \beta}$ می‌توان وزن خطاها را به گونه‌ای تنظیم کرد که مدل به سمت اتخاذ تصمیمی مشابه دسته‌بند $f(x) = 1$ سوق داده شود؛ به بیان دیگر، ریسک مورد انتظار این دسته‌بند ساده تحت تابع خطای جدید کمینه گردد.

(ب) مسئله‌ی طبقه‌بندی دودویی زیر را در نظر بگیرید. ابتدا برچسب Y به صورت تصادفی و مستقل از توزیع $\text{Bernoulli}(\frac{1}{4})$ انتخاب می‌شود؛ یعنی با احتمال $\frac{1}{4}$ مقدار ۱ و با همان احتمال مقدار ۰ دارد. سپس، به طور شرطی بر مقدار Y ، متغیر ویژگی X به صورت زیر تولید می‌شود:

• اگر $Y = 1$ ، آنگاه $X \sim \text{Bernoulli}(p)$

• اگر $Y = 0$ ، آنگاه $X \sim \text{Bernoulli}(q)$

در اینجا فرض می‌کنیم $p > q$ ، بنابراین مقدار $X = 1$ در کلاس ۱ محتمل‌تر از کلاس ۰ است. هدف، یافتن دسته‌بند بهینه‌ی بیز برای پیش‌بینی برچسب Y بر اساس مشاهده‌ی X و همچنین محاسبه‌ی ریسک (خطر) متناظر با آن است.

(ج) مسئله‌ی طبقه‌بندی دودویی با دو کلاس هم‌احتمال را در نظر بگیرید که در آن

$$P(y = 0) = P(y = 1) = \frac{1}{2}.$$

ویژگی‌های دو بعدی $x \in \mathbb{R}^2$ در هر کلاس به صورت شرطی از توزیع‌های گوسی زیر نمونه‌برداری می‌شوند:

$$X | (Y = 0) \sim \mathcal{N}(\mu_0, \Sigma_0), \quad X | (Y = 1) \sim \mathcal{N}(\mu_1, \Sigma_1)$$

با فرض برابری میانگین‌ها، یعنی $\mu_0 = \mu_1$. برای حالت خاص زیر:

$$\Sigma_0 = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}, \quad \Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix},$$

کانتورهای مربوط به توابع چگالی شرطی هر کلاس را ترسیم کنید و آن‌ها را به ترتیب با $p(x|y=0)$ و $p(x|y=1)$ برچسب‌گذاری نمایید. سپس مرز تصمیم‌گیری بیزین را مشخص کرده و نواحی مربوط به پیش‌بینی هر کلاس را نمایش دهید.

۶. متأسفانه تعداد زیادی موجود فضایی ناشناخته به شهر ایوب یورک (*AyoubYork*) حمله کرده‌اند؛ اما همه آن‌ها برای مردم خطرناک نیستند و بعضاً رفتار دوستانه‌ای دارند. برای تشخیص این ویژگی، مجموعه داده‌های آموزشی در اختیار ما قرار گرفته است که شامل ویژگی‌های وزن (که می‌تواند دو مقدار چاق و عادی باشد)، رنگ چشم (دو مقدار آبی و بنفش) و تعداد چشم (که می‌تواند ۳، ۲ یا ۴ باشد) است.

نمای کلی این مجموعه داده به شرح زیر است:

خطرناک؟	تعداد چشم	رنگ چشم	وزن
خیر	۲	آبی	عادی
خیر	۲	بنفش	عادی
خیر	۲	بنفش	عادی
خیر	۳	بنفش	چاق
خیر	۳	بنفش	چاق
بله	۴	آبی	چاق
بله	۴	آبی	عادی
بله	۴	بنفش	عادی
بله	۳	آبی	چاق
بله	۳	آبی	چاق

در تمام بخش‌های زیر، در صورت تساوی بین تعداد برچسب‌ها در یک برگ، موجود فضایی را بی‌خطر در نظر بگیرید.

(الف) درخت تصمیم را با نشان دادن تمام مراحل و محاسبات رسم کنید.

(ب) اگر بخواهیم درخت را یک مرحله زودتر خاتمه دهیم و عمق آن را یک سطح کمتر کنیم، برای هر برگ تعیین کنید چه برچسبی اختصاص داده خواهد شد.

(ج) فرض کنید به دلیل حساسیت بالاتر در شناسایی موجودات خطرناک و حفظ امنیت شهر، جریمه‌ی تشخیص اشتباه نمونه‌های خطرناک ۴ برابر جریمه‌ی اشتباه تشخیص موجودات بی‌آزار باشد. در این صورت، برگ‌های مرحله قبل چگونه برچسب‌گذاری خواهند شد؟

(د) برای بخش‌های (الف) و (ب)، مقادیر دقت (Accuracy)، دقت مثبت کاذب (Precision)، بازیابی (Recall) و F1 Score را روی داده‌های آموزشی محاسبه کنید.

۷. (الف) اشکال تخمین زدن احتمال $P(A|B)$ به صورت تعداد رخداد B چیست؟

(ب) توضیح دهید هر کدام از روش‌های زیر چه تأثیری در بیش‌برازش مدل‌ها دارند:

- کم کردن تعداد برگ‌ها در درخت تصمیم
- محدود کردن حداکثر طول درخت تصمیم

درباره تأثیر آن‌ها در دقت مدل در داده‌های آموزش چه می‌توان گفت؟

۸. (الف) یادگیری مبتنی بر نمونه (Instance-Based Learning) چیست؟ این روش چه تفاوتی با

یادگیری مدل‌محور (Model-Based Learning) دارد؟ به کمک یک مثال عددی یا هندسی این تفاوت را توضیح دهید.

(ب) در الگوریتم k -NN می‌توان به جای وزن‌دهی مساوی به همسایگان، از وزن‌دهی فاصله‌محور استفاده کرد. فرض کنید وزن نقطه‌ی x_i نسبت به نقطه پرس‌وجو x به صورت زیر تعریف شده است:

$$w_i = \frac{1}{\|x - x_i\|^2 + \epsilon}$$

- نشان دهید که این وزن‌دهی باعث تأکید بیشتر بر نزدیک‌ترین همسایگان می‌شود.
- نقش پارامتر ϵ را بررسی کنید و توضیح دهید در چه شرایطی باید بزرگ یا کوچک باشد.


(ج) چرا الگوریتم‌های مبتنی بر نمونه مانند k -NN برای درونیابی (Interpolation) مناسب هستند ولی برای

برونیابی (Extrapolation) ضعیف عمل می‌کنند؟ پاسخ خود را با تحلیل هندسی یا یک تابع نمونه مانند $f(x) = \sin(x)$ برای نقاط محدود ارائه دهید.

۹. روش خوشه‌بندی k -means را در نظر بگیرید و فرض کنید که می‌خواهیم داده‌های شکل ۱ را با استفاده از این روش به دو خوشه تقسیم کنیم. همان‌گونه که می‌دانید، در الگوریتم k -means ابتدا داده‌ها به صورت تصادفی به دو خوشه نسبت داده شده و سپس مرکز (میانگین) هر خوشه محاسبه می‌شود. در ادامه، با استفاده از معیار فاصله‌ی اقلیدسی، تعلق هر داده به نزدیک‌ترین مرکز به‌روزرسانی می‌گردد. این فرایند تا زمانی که تغییری در تعلق داده‌ها و در نتیجه در مراکز خوشه‌ها ایجاد نشود، تکرار می‌شود.

(الف) اگر الگوریتم k -means را روی داده‌های شکل ۱ اعمال کنیم، چه مشکلی پدید می‌آید؟

(ب) تبدیلی چون $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ معرفی کنید که با اعمال آن بر روی داده‌ها، در فضای جدید، دو خوشه به‌راحتی با الگوریتم k -means قابل جداسازی باشند.



شکل ۱: داده‌های ورودی برای خوشه‌بندی

اکنون به روش دیگری می‌اندیشیم. فرض کنید به هر داده‌ی X_i مقداری $0 \leq p_i \leq 1$ نسبت دهیم. هرچه p_i به صفر نزدیک‌تر باشد، «احتمال» انتساب X_i به خوشه‌ی نخست بیشتر است و هرچه به ۱ نزدیک‌تر شود، احتمال تعلق آن به خوشه‌ی دوم افزایش می‌یابد. در نهایت، با آستانه‌گذاری حول $\frac{1}{2}$ ، خوشه‌ی هر داده مشخص می‌شود. هدف، برآورد p_i ها برای همه‌ی داده‌هاست. رستم مسئله‌ی بهینه‌سازی زیر را برای حل این مسئله پیشنهاد می‌کند ($\sigma > 0$ پارامتر قابل تنظیم است):

$$\min_{p_1, \dots, p_n} \sum_{i,j=1}^n e^{-\frac{\|X_i - X_j\|_2^2}{\sigma^2}} (p_i - p_j)^2 \quad \text{s.t.} \quad p_i \in [0, 1], \quad \forall i.$$

ایده‌ی اصلی این است که با انتخاب σ مناسب، اگر X_i و X_j از نظر اقلیدسی به هم نزدیک باشند، آنگاه p_i و p_j نیز به هم نزدیک شوند و در نتیجه در یک خوشه قرار گیرند.

(الف) اگرچه ایده‌ی رستم در نگاه اول منطقی به نظر می‌رسد، اما حل مسئله‌ی نوشته‌شده کمکی به خوشه‌بندی نمی‌کند. دلیل این امر را توضیح دهید.

(ب) فرض کنید می‌خواهیم مسئله‌ی فوق را با استفاده از الگوریتم گرادیان کاهشی (GD) حل کنیم. چه مشکلی رخ خواهد داد؟ الگوریتم در چه نقطه‌ای متوقف می‌شود؟ با محاسبه‌ی گرادیان نشان دهید که با افزایش تعداد تکرارها چه اتفاقی می‌افتد.

تهمینه، فرمول‌بندی رستم را به صورت زیر اصلاح می‌کند:

$$\min_{p_1, \dots, p_n} \sum_{i,j=1}^n \left\{ e^{-\frac{\|X_i - X_j\|_2^2}{\sigma^2}} (p_i - p_j)^2 + \left(1 - e^{-\frac{\|X_i - X_j\|_2^2}{\sigma^2}} \right) (1 - p_i - p_j)^2 \right\}.$$

(الف) توضیح دهید که چرا فرمول‌بندی تهمینه، مشکل فرمول‌بندی رستم را برطرف می‌کند. به عبارت دیگر، مزیت فرمول‌بندی تهمینه نسبت به فرمول‌بندی رستم چیست؟

(ب) آیا فرمول‌بندی تهمینه می‌تواند داده‌های شکل ۱ را به درستی خوشه‌بندی کند؟ چگونه؟

(ج) درباره‌ی نقش پارامتر σ بحث کنید. مقادیر بسیار کوچک یا بسیار بزرگ این پارامتر چه مشکلاتی ایجاد می‌کنند؟