

۱. نقاط زیر را در نظر بگیرید:

x	y
۱	۴
۲	۵
۳	۹

می‌خواهیم با یک تابع ثابت برای تخمین شروع کنیم و در هر مرحله با یک درخت تصمیم به عمق یک و با ضریب انتخاب دو مدل خود را آموزش دهیم. در این فرآیند از روش Gradient Boosting با ضریب یادگیری ۰.۱ استفاده می‌کنیم و می‌خواهیم بردار y را تخمین بزنیم.

در این روش برای انتخاب نقطه‌ی جداسازی در هر دور از درخت تصمیم، از نقطه‌ای به طول میانگین نقاط اطراف آن استفاده می‌کنیم و جداکننده با خطای کمتر را انتخاب می‌کنیم.

همچنین برای محاسبه خطا از تابع Squared Error استفاده می‌کنیم. بردار y را پس از دو مرحله پیشروی با مفروضات داده‌شده بیابید.


۲. هدف الگوریتم K-Means کمینه‌سازی پراکندگی درون‌خوشه‌ای است. با داشتن یک ماتریس داده $D \in \mathbb{R}^{n \times d}$ و تعداد خوشه‌ها r ، هدف یافتن خوشه‌های $C_1, \dots, C_r \subseteq \{1, \dots, n\}$ است به‌طوری که یک افراز از مجموعه نمونه‌ها ایجاد کنند و فاصله بین تمامی نقاط درون خوشه‌ها را کمینه کنند:

$$\min_{C_1, \dots, C_r \subseteq \{1, \dots, n\}} \text{Dist}(C_1, \dots, C_r) = \sum_{s=1}^r \frac{1}{|C_s|} \sum_{i,j \in C_s} \|D_j - D_i\|^2$$

ثابت کنید الگوریتم K-Means با نتیجه‌ی زیر معادل است، یا به عبارتی اگر خوشه‌ها را طوری انتخاب کنیم که معادله‌ی قبلی برقرار شود، فاصله‌ی تمامی نقاط هر خوشه از مرکز آن خوشه نیز کمینه می‌شود:

$$\min \sum_{s=1}^r \sum_{i \in C_s} \|D_i - X_s\|^2 \quad \text{s.t.} \quad X_s = \frac{1}{|C_s|} \sum_{i \in C_s} D_i, \quad C_1, \dots, C_r \subseteq \{1, \dots, n\}$$

۳. آیا می‌توان GMM را به‌صورت مدلی با یک متغیر latent در نظر گرفت که در آن هر نمونه‌ی داده ابتدا با انتخاب تصادفی یکی از مؤلفه‌ها تولید می‌شود و سپس از یک توزیع نرمال مربوط به آن مؤلفه نمونه‌گیری انجام می‌شود؟ به عبارت دیگر، آیا توزیع حاشیه‌ای داده‌ها در GMM معادل با حاشیه‌گیری (marginalization) از روی یک متغیر پنهان گسسته است؟



شکل ۱: نمونه‌ای از توزیع گوسی دو متغیره

۴. فرض کنید $x \in \mathbb{R}^D$ برداری D -بعدی باشد. توزیع گاوسی چندمتغیره با میانگین $\mu \in \mathbb{R}^D$ و کوواریانس $\Sigma \in \mathbb{R}^{D \times D}$ متقارن به صورت زیر تعریف می‌شود:

$$\mathcal{N}(x | \mu, \Sigma) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$$

به طوری که $\mathbb{E}[x] = \mu$ و $\text{Cov}[x] = \Sigma$. در حالت یک‌بعدی ($D=1$)، رابطه فوق به همان فرمول چگالی توزیع نرمال معمولی تک متغیره تبدیل می‌شود.

حال که با این توزیع آشنا شدید، فرض کنید z یک متغیر تصادفی K بعدی است که در آن $z_k \in \{0, 1\}$ و $\sum_k z_k = 1$ است. ای متغیر تصادفی یک متغیر نهان است و در صورتی که بعد k ام آن برابر با یک باشد یعنی داده به خوشه‌ی k ام تعلق دارد. همچنین فرض کنید که $p(z_k = 1) = \pi_k$ باشد که $0 \leq \pi_k \leq 1$ و $\sum_{k=1}^K \pi_k = 1$ است. در این صورت می‌توانیم $p(z)$ را به صورت زیر بنویسیم.

$$p(z) = \prod_{k=1}^K \pi_k^{z_k}$$

همچنین فرض کنید توزیع $p(x|z_k = 1)$ به صورت زیر باشد:

$$p(x|z_k = 1) = \mathcal{N}(x|\mu_k, \Sigma_k)$$

(الف) نشان دهید توزیع $p(x)$ به صورت زیر است.

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

(ب) نشان دهید که $\gamma(z_{nk}) = p(z_k = 1|x_n)$ به صورت زیر است.

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n|\mu_j, \Sigma_j)}$$

(ج) فرض کنید داده‌های D بعدی $\{x_1, x_2, \dots, x_N\}$ به ما داده شده است. می‌توانیم این داده‌ها را در یک ماتریس $N \times D$ بعدی X نشان دهیم. همچنین معادلات به ازای هر داده متغیر نهان را با ماتریس $N \times K$ بعدی Z نشان می‌دهیم. عبارت

لگاریتم بیشینه‌ی درستنمایی برای این داده‌ها به صورت زیر است:

$$\ln p(X|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(x_n | \mu_k, \Sigma_k) \right\}$$

(د) فرض کنید $k \geq 2$ و همچنین برای سادگی فرض کنید $\Sigma_k = \sigma_k^2 I$ که در آن I ماتریس همانی است. نشان دهید در بیشینه کردن تابع درستنمایی حالتی وجود دارد که در آن اگر $\sigma_k \rightarrow 0$ برود تابع درستنمایی به سمت ∞ می‌رود.

(ه) نشان دهید چرا در صورتی که $k = 1$ باشد اتفاق بخش پیشین امکان رخ دادن ندارد.

(و) از تابع لگاریتم درستنمایی نسبت به μ_k مشتق بگیرید و نشان دهید:

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_n$$

$$N_k = \sum_{n=1}^N \gamma(z_{nk})$$

راهنمایی:

برای ماتریس متقارن B و بردارهای a, v داریم: $\frac{\partial (a-v)^T B (a-v)}{\partial v} = -2B(a-v)$ (ز) از تابع لگاریتم درستنمایی نسبت به Σ_k مشتق بگیرید و نشان دهید:

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k)(x_n - \mu_k)^T$$

قواعد مشتق برای راهنمایی:

$$\frac{\partial f(x)}{\partial x} = f(x) \frac{\partial}{\partial x} \ln f(x) \bullet$$

$$\frac{\partial}{\partial A} \ln |A| = A^{-T} \bullet$$

$$\frac{\partial}{\partial A} x^T A^{-1} x = -(A^{-T} x x^T A^{-T}) \bullet$$

از آنجایی که شرط $\sum_k \pi_k = 1$ را داریم نمی‌توان برای بدست آوردن π_k به صورت مستقیم از مشتق گیری استفاده کرد. برای این کار از روشی به اسم ضرایب لاگرانژ استفاده می‌شود که در آن به جای تابع درستنمایی باید از تابع زیر بهره گرفت:

$$\ln p(X|\pi, \mu, \Sigma) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right)$$

با مشتق‌گیری از عبارت بالا:

(ح) ثابت کنید که $\lambda = -N$ و $\pi_k = \frac{N_k}{N}$ است.

۵. فرض کنید داده‌های $x_1, \dots, x_n \in \mathbb{R}^d$ را با الگوریتم K-Means به K خوشه افراز کرده‌اید. حال داده‌ها را با یک نگاشت $\phi: \mathbb{R}^d \rightarrow \mathcal{H}$ به فضای ویژگی با هسته‌ی $\kappa(x, x') = \langle \phi(x), \phi(x') \rangle$ منتقل می‌کنیم و K-Means را در فضای $\mathcal{H}$ اجرا می‌کنیم.

(الف) نشان دهید که مراکز خوشه در فضای $\mathcal{H}$ را می‌توان به صورت ترکیبی خطی از $\phi(x_i)$ ‌ها نمایش داد.

- (ب) با استفاده از ترفند هسته، معیار کمینه‌سازی فاصله‌ی نقاط از مرکز خوشه در فضای $\mathcal{H}$ را تنها بر حسب ماتریس هسته K (با $K_{ij} = \kappa(x_i, x_j)$) و ماتریس نشانگر عضویت M بازنویسی کنید (بدون نیاز به محاسبه‌ی صریح ϕ).
- (ج) توضیح دهید که در این روش، مراکز خوشه‌ها ممکن است نمایش مستقیم در فضای ورودی نداشته باشند و این موضوع چه تأثیری بر تفسیرپذیری مدل دارد.

۶. در روش Gradient Boosting به‌جای کمینه‌سازی مستقیم تابع هزینه، در هر مرحله یک مدل پایه به‌سمت منفی گرادیان تابع هزینه برازش داده می‌شود. فرض کنید تابع هزینه $L(y, f(x))$ یک تابع مقعر نسبت به f نباشد. آیا الگوریتم Gradient Boosting تضمین می‌کند که تابع هزینه روی داده‌های آموزش در هر گام کاهش یابد؟ اگر نه، چه شرطی روی تابع هزینه (یا روی نرخ یادگیری) لازم است تا کاهش در هر گام تضمین شود؟ پاسخ خود را با اشاره به مفهوم «بهینه‌سازی در فضای تابعی» و نقش نرخ یادگیری توضیح دهید.

سه مؤلفه‌ی گوسی با میانگین‌های

$$\mu_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mu_2 = \begin{bmatrix} 5 \\ 0 \end{bmatrix}, \quad \mu_3 = \begin{bmatrix} 0 \\ 5 \end{bmatrix}$$

و ماتریس‌های کوواریانس

$$\Sigma_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, \quad \Sigma_3 = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}$$

با وزن‌های $\pi_1 = 0.5, \pi_2 = 0.3, \pi_3 = 0.2$ در نظر بگیرید.

- (الف) الگوریتم EM را برای این GMM به‌صورت گام‌به‌گام شرح دهید. نشان دهید که اگر اولیه‌سازی بسیار بد انتخاب شود (مثلاً $\mu_1 = \mu_2 = \mu_3$ یا $\pi_2 = 0$)، الگوریتم ممکن است به یک نقطه‌ی بیشینه‌ی محلی غیربهینه همگرا شود. برای یکی از این حالات، توضیح دهید که چه اتفاقی برای $\gamma(z_{nk})$ می‌افتد.
- (ب) پیشنهاد دهید که چگونه می‌توان با استفاده از خروجی K-Means به‌عنوان مرحله‌ی اولیه‌سازی، احتمال افتادن در نقاط محلی غیربهینه را کاهش داد.

۷. نشان دهید که اگر داده‌ها شامل حداقل یک نقطه‌ی پرت (Outlier) باشد، افزایش تعداد خوشه‌ها در K-Means (حداقل به اندازه‌ی تعداد نقاط پرت) می‌تواند مقدار تابع هدف (پراکندگی درون‌خوشه‌ای) را به‌شدت کاهش دهد. این پدیده را با یک مثال ساده در $\mathbb{R}$ توضیح دهید؛ مثلاً داده‌های $\{0, 1, 2, 100\}$ را با $K = 2$ و $K = 3$ مقایسه کنید. آیا این رفتار نشان‌دهنده‌ی ضعف K-Means در برابر داده‌های ناهمگون است؟ یک راهکار پیشنهاد دهید.

۸. فرض کنید داده‌ها را با یک تبدیل خطی $x' = Ax$ (که A یک ماتریس ناتکین $D \times D$ است) تغییر می‌دهیم. نشان دهید که اگر یک GMM با کوواریانس‌های کامل (General Covariance) روی داده‌ی اصلی x آموزش دیده باشد، پارامترهای مدل روی داده‌ی تبدیل‌یافته x' چگونه تغییر می‌کنند؟ آیا با انتخاب یک A مناسب می‌توان کوواریانس‌های همه‌ی مؤلفه‌ها را به‌صورت یکسان (کروی) درآورد؟ پاسخ خود را با استفاده از فرمول تبدیل متغیر تصادفی در توزیع گوسی توجیه کنید.